

Potabilidad del agua

Proyecto de Adquisición, Análisis y
Procesamiento de Datos

Ana Cabrera Gutiérrez




Objetivo

Analizar muestras de agua para preparar una base que permita predecir si el agua es potable o no.


- *Dataset de calidad del agua.*



- *Variables físico-químicas.*



- *Variable objetivo: Potability.*



¿Qué mide el dataset?



Acidez o
alcalinidad.

Turbidez.

Minerales
y sales.

Potabilidad.

Desinfección.

Variables independientes


Variable	Medida	Descripción
ph	Escala 0–14	Acidez o alcalinidad del agua.
Hardness	mg/L	Dureza del agua por minerales como calcio y magnesio.
Solids	ppm	Sólidos disueltos totales.
Chloramines	ppm	Compuestos usados para desinfección.
Sulfate	mg/L	Sulfatos disueltos.
Conductivity	μS/cm	Capacidad del agua para conducir electricidad.
Organic_carbon	ppm	Carbono orgánico presente.
Trihalomethanes	μg/L	Subproductos de procesos de desinfección.
Turbidity	NTU	Turbidez o falta de claridad del agua.

Variable objetivo

Potability

- 0: Agua NO potable.
- 1: Agua potable.


Hay más muestras no potables que potables.



Datos faltantes

Se encontraron nulos en:

- *ph*
- *Sulfate*
- *Trihalomethanes*



Criterio de limpieza de nulos

X

0

X

Desechar todo

ELIMINAR

3 variables nulos

2 nulos con ph

Eliminar los valores mas inciertos


IMPUTAR LA MEDIANA

2 nulos sin ph

1 variable nula

Outliers

Muy presentes en el dataset



Outliers potables

- Outlier posible

- ¿es físicamente posible?
- valores acorde a la medida

- Inconsistencia fuerte

- ¿contradice fuertemente la potabilidad?

Criterios:

- *pH extremadamente alto.*
- *pH extremadamente bajo.*
- *sólidos o cloraminas altas.*

Muestras potables raras

1. Fórmula



*media $\pm$ 3 desviaciones
estándar*


2. Cantidad de valores raros por fila



```
indice_fila
263      2
810      2
1186     2
1554     2
272      2
..
2376     1
3184     1
382      1
1073     1
1892     1
Name: count, Length: 76, dtype: int64
```

Muestras potables raras

3. Cantidad de valores raros >2




ph = imposible para potabilidad


	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	Turbidity	Potability
indice_fila										
263	13.175402	47.432000	19237.949676	8.907020	375.147315	500.245952	12.083896	66.608891	4.106924	1
810	0.989912	133.216942	16922.853899	9.293289	444.375731	322.291191	10.430076	43.578466	5.160604	1
1186	9.484703	122.906991	56351.396304	4.219711	219.553437	480.848063	13.533433	41.731219	4.132274	1
1554	8.942046	215.673786	56488.672413	3.231438	129.000000	541.915468	9.313771	70.828374	4.354288	1
272	6.512737	229.263861	22475.046873	12.580026	192.033592	479.501279	9.983462	66.668576	4.612964	1
275	5.324942	280.089655	35344.658047	13.043806	180.206746	392.421496	10.504820	55.084668	4.427138	1
351	8.848586	188.919983	32033.332019	13.127000	182.397370	479.791975	12.070444	77.671337	4.014682	1




Poca correlación




**Las clases
se mezclan**



Las clases se mezclan



Las clases se mezclan



Criterio de Feature Engineering


se agruparon características relacionadas con fenómenos del agua.

Nueva variable	Variables involucradas	Tipo
ph_fuera_rango	ph	Binaria
ph_categoria	ph	Categórica
turbidez_alta	Turbidity	Binaria
riesgo_desinfeccion	Chloramines, Trihalomethanes, Organic_carbon	Numérica ordinal
carga_mineral_alta	Hardness, Solids, Sulfate, Conductivity	Numérica ordinal

PH


ph_fuera_rango

marca si el pH está fuera de
6.5–8.5.



ph_categoria

clasifica el agua como ácida,
aceptable o alcalina.




Turbidez

turbidez_alta

Se usó la variable Turbidity

Es binaria e indica si la muestra presenta turbidez mayor al 75% de los datos




Riesgo de desinfección

riesgo_desinfeccion

Se combinaron:

- Chloramines
- Trihalomethanes
- Organic_carbon

Estas variables están relacionadas con desinfección, subproductos químicos y materia orgánica




Carga mineral alta o iónica

carga_mineral_alta

Se combinaron:

- Hardness
- Solids
- Sulfate
- Conductivity

Acumulación de minerales y sólidos disueltos.



Resultado del feature engineering



Se consevaron las variables originales



Las nuevas variables resumen condiciones físico-químicas importantes.



Se agregaron variables derivadas más interpretables.




El dataset queda más preparado para una futura etapa de modelado.

Resultado final del dataset

La base quedó limpia, estructurada y enriquecida para la siguiente fase del proyecto.

- *Dataset original: 3276 registros.*
- *Dataset final: 3145 registros.*
- *Sin valores nulos.*
- *Sin duplicados.*
- *Con inconsistencias fuertes tratadas.*
- *Con nuevas variables derivadas.*



CONCLUSIONES

La potabilidad no se explica con una sola variable.

Las clases aparecen mezcladas en las visualizaciones.

La limpieza combinó eliminación selectiva e imputación.

Los outliers no se eliminaron automáticamente.

Se crearon variables nuevas con criterio físico-químico.

El dataset quedó listo para la siguiente fase.

La primera fase permitió convertir el dataset original en una base más confiable e interpretable.